

Compte-rendu TP1

Support Vector Machine & Decision trees

B. SVM non linéaire à noyau gaussien


1) Génération des données

b) En appliquant le modèle linéaire sur les données, on obtient une précision qui varie entre 50% et 87%.

Ce jeu de données ne suit pas une distribution linéaire. Donc le modèle SVM linéaire précédent n'est pas optimal, on obtient néanmoins environ 85% de précision.

2) Analyser l'influence du paramètre de dispersion (spread) du noyau.

b) Nous avons regardé certaine valeurs de gamma, (0.01, 0.1, 1, 10, 100), voici les résultats obtenus:



Sur le graphique ci-dessus, on observe que la précision optimale de ce modèle est obtenue lorsque $\gamma = 10$, puis l'augmentation de ce paramètre n'améliore plus la précision. C'est aussi le gamma avec le moins de vecteur support

Gamma	Erreur Apprentissage	Erreur Test	Nombre de vecteurs supports
0.01	17.14%	13.6%	374
0.10	12.85%	10.6%	252
1.00	3.57%	5%	110
10.00	2.71%	4%	102
100.00	1.71%	5.3%	261

C) En faisant varier le paramètre gamma, nous nous sommes aperçu que plus celui-ci augmente, plus l'erreur d'apprentissage et l'erreur test diminuent.

Cependant lorsque Gamma devient trop grand, le nombre de vecteurs supports ré-augmente et l'erreur test augmente aussi, on fait du sur apprentissage. La meilleur valeur de gamma que nous avons trouvé parmi notre ensemble de test est: $\gamma = 10$

3) Optimisation par recherche en grille (grid search)

b) En appliquant une recherche en grille avec une validation croisée à 5 plis, on obtient un résultat proche de la recherche d'hyper paramètres précédente.

Voire le tableau ci-dessous :


C	Gamma	Précision données test	Nombre vecteurs supports	Tps d'inférence
2	9	97%	136	environ 0,002 s

C. Decision trees



1) Analyser l'impact des paramètres (critères d'arrêt de l'apprentissage)

a) Conclure sur l'impact du paramètre max depth:

Nous avons fait varier max_depth de 1 à 100. Nous remarquons qu'en faisant évoluer ce paramètre, l'algorithme des arbres de décisions atteint 96% de précision sur les données test avec un paramètre max_depth égal à 5. Cependant, il a ensuite tendance à sur-apprendre et à stagner dans les 95% de précision.



b) En fixant max_depth à 'none' et en faisant varier min_samples_split entre 1 et 100, on obtient un arbre de profondeur 5. On observe que le score sur les données test augmente légèrement et atteint son optimum à min_samples_split = 50, mais sur-apprend par la suite, et diminue donc son score.




2) Optimisation par recherche en grille (grid search)

Frontières	Précision sur la base de test	Temps d'inférence	
7	96.0%	0.005 s	

b) On peut conclure que la précision entre les 2 modèles est équivalente avec une petite préférence pour la SVM car nous avons trouvé environ 97% de précision pour la SVM et 96% pour l'arbre de décision.

D. Extra trees.

- 1) En utilisant les extra trees, l'aléatoire de la génération d'arbres est accrue comparée aux arbres précédents. De plus, cette génération aléatoire est plus rapide que la génération de nouvelles frontières à chaque étape.
- 2) Sur ce graphique en boîte à moustache on observe que, sur les 20 scores obtenus, les données entre le premier et le troisième quartile sont comprises entre 91% et 93%. La meilleure précision obtenue lors d'un test est de 95% tandis que le minimum est de 91%. Quant au score d'apprentissage, il reste à 100%.



Conclusion

On constate que l'on obtient des résultats similaires en précision avec la SVM et les arbres de décision. La recherche des hyperparamètres permet d'améliorer la précision des modèles.