

# MACHINE LEARNING CHALLENGE

## 5A

Reconnaissance d'émotions

2024 - 2025

Tanguy VALIN  
Orlane GRUET  
Victor BOUVIER D'ACHER  
Geoffroy RODRIGUEZ

Professeur :  
Monsieur GEOFFROY

# Table des matières

|                                                                                                                                                                                                                      |           |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------|
| <b>Table des matières.....</b>                                                                                                                                                                                       | <b>2</b>  |
| <b>1. Introduction.....</b>                                                                                                                                                                                          | <b>3</b>  |
| <b>2. Data Exploration &amp; data preparation.....</b>                                                                                                                                                               | <b>3</b>  |
| Traitement des valeurs aberrantes.....                                                                                                                                                                               | 3         |
| Nous avons effectué une batterie de tests sur le dataset d'entraînement pour détecter d'éventuelles valeurs aberrantes ou manquantes. Nous avons utilisé la librairie pandas pour réaliser les tests suivants :..... | 3         |
| Data exploration.....                                                                                                                                                                                                | 4         |
| <b>3. Exploration des différents modèles SVM.....</b>                                                                                                                                                                | <b>7</b>  |
| Modèles SVM classique.....                                                                                                                                                                                           | 7         |
| 1 - Approche Naïve.....                                                                                                                                                                                              | 7         |
| 2 - Réduction dimensionnelle.....                                                                                                                                                                                    | 7         |
| 3 - Recherche des meilleurs hyper-paramètres.....                                                                                                                                                                    | 8         |
| 4 - Architecture du SVM et évaluation.....                                                                                                                                                                           | 9         |
| Approche par LBP.....                                                                                                                                                                                                | 10        |
| 1 - La démarche.....                                                                                                                                                                                                 | 10        |
| 2 - Evaluation du modèle.....                                                                                                                                                                                        | 11        |
| <b>Conclusion.....</b>                                                                                                                                                                                               | <b>11</b> |

# 1.Introduction

Le projet que nous devons réaliser porte sur la reconnaissance d'émotion à partir de photos de visages expressifs.

Pour ce faire, nous avons accès à une base de données contenant des photos de visages expressifs ainsi que leur expression faciale exprimée (du modèle d'Ekman): joie, colère, dégoût, tristesse, peur, surprise et neutre.

Il nous est aussi partagé un ensemble de features, correspondant aux coordonnées de points situés sur les visages correspondants et à leurs extrémités.

Nous devons donc, à partir de ces informations et des 977 exemples présents dans une base de données, réaliser un modèle de machine learning qui, grâce à des landmarks donnés, permettra de déterminer l'émotion exprimée par un visage.


## 2.Data Exploration & data preparation

### Traitement des valeurs aberrantes

Nous avons effectué une batterie de tests sur le dataset d'entraînement pour détecter d'éventuelles valeurs aberrantes ou manquantes. Nous avons utilisé la librairie pandas pour réaliser les tests suivants :

- Recherche de valeurs manquantes : il s'est avéré qu'aucune valeur manquante n'est présente dans l'ensemble du jeu de données.
- Recherche de doublons : Aucune ligne n'est présente deux fois dans le dataset. En revanche, 6 lignes présentent des id en double. Cela qui correspond à des valeurs aberrantes puisqu'un id est censé correspondre au nom d'une image de notre base de données.

Nous avons ensuite vérifié manuellement ces 6 doublons pour déterminer quelle était la valeur aberrante entre les deux entrées différentes. Par exemple, la ligne 338 et la ligne 382 affichaient toutes les deux l'ID *48738.jpg* mais présentait des labels différents (*anger* vs *surprise*) et des landmarks avec des coordonnées différentes. Pour déterminer quelle ligne était la bonne, il suffit de visualiser les deux exemples :




Il est aisé de remarquer que l'exemple avec le label *anger* n'est pas le bon. Nous l'avons donc supprimé du dataset, puis fait de même avec les 5 autres doubles-id présents dans le jeu de données. Nous avons choisi de simplement supprimer ces valeurs aberrantes car elles étaient présentes en très faible nombre (6 entrées sur 977).

Nous nous sommes également aperçus que deux images étaient de dimension 4000x3000, contrairement aux autres qui sont au format 1000x750. Les landmarks de ces images ont des valeurs largement plus grandes que ceux des autres images. Nous les avons donc considérées comme des valeurs aberrantes (images 89947.pdf et 83537.pdf).

## Data exploration


A cette étape du projet, nous avons commencé par réaliser différentes visualisations de notre dataset. Nous avons testé d'une part s'il contenait suffisamment d'exemples et était bien équilibré (assez d'exemples pour chaque émotion), et d'autre part si tous les landmarks étaient pertinents pour discriminer chaque émotion.

Après le nettoyage de données, le dataset contient 971 exemples classés en 7 labels avec la répartition suivante :



Le dataset d'entraînement est bien équilibré, malgré une légère absence d'exemples de la classe *neutral* et une absence plus importante d'exemples en *happy*. Mais tous les labels dépassent les 10% d'exemples sur la base de données, ce qui garantit au moins approximativement 100 exemples pour chaque classe. Ce que nous considérons comme suffisant pour réaliser nos tests.

Pour ce qui relève de l'importance de chaque features (les landmarks), nous avons réalisé une visualisation des landmarks moyens par émotions. Cela consiste à grouper notre jeu de données par émotions et de calculer une position moyenne par landmarks. Vous trouverez le résultat ci-dessous.



Nous remarquons que presque aucun landmarks moyen par émotion ne se superpose. Nous observons aussi que pour certains landmarks apparaissent plus de variances en fonction des labels.

Tous les landmarks semblent donc avoir une importance, mais certains pourraient discriminer les émotions mieux que d'autres. Ce sont notamment les landmarks présents au niveau des sourcils, de la bouche et des yeux qui permettent de mieux différencier les émotions. Les landmarks de la mâchoire et du nez varient aussi mais plus discrètement.

En effet, les sourcils et la bouche changent largement de position et de forme en fonction des émotions. La mâchoire, elle, est plus fixe.

Il est également important de noter que la distinction entre les émotions "sad" et "neutral" est souvent plus difficile à établir, en raison de la nature moins marquante des expressions faciales associées à ces deux émotions. Les différences subtiles comme un affaissement léger des coins de bouche rendent plus difficile une classification bien établie entre les deux émotions.

## 3.Exploration des différents modèles SVM

Il apparaît dans plusieurs études sur la détection d'émotions<sup>1</sup> que les modèles SVM (Support Vector Machine) présentent de bonnes performances. Comme ce modèle est plus léger qu'un modèle de type Deep-Learning, et comme notre dataset de taille modeste (≈ 1000 exemples) ne permet pas forcément d'entraîner de gros modèles, nous avons exploré les performances des SVM.

### Modèles SVM classique

#### 1 - Approche Naïve

Dans un premier temps, nous avons entraîné un modèle SVM issu de la bibliothèque sklearn directement sur notre dataset après normalisation. C'est-à-dire directement sur les landmarks fournis via un fichier csv. Pour ce qui est du choix des hyperparamètres (C, le degré, le noyau, ...), nous avons réalisé une première recherche dans un espace réduit en explorant 350 possibilités, notamment des noyaux linéaires et non-linéaires pour différentes valeurs de C. Nous avons ainsi déterminé nos meilleurs hyperparamètres à priori :

'C': 10, 'degree': 2, 'gamma': 'scale', 'kernel': 'linear'.

Pour un taux de reconnaissance à **72%** sur la base de test.


#### 2 - Réduction dimensionnelle

Après notre phase d'analyse exploratoire des données, il nous était apparu que toutes les features n'avaient pas la même importance pour discriminer les émotions. Nous avons alors pensé qu'une réduction préalable de dimensions en gardant seulement les axes principaux pourrait peut-être améliorer les performances de notre SVM. Nous avons donc réalisé une PCA et testé notre SVM après réduction dimensionnelle, vous trouverez ci-dessous les résultats en fonction du nombre d'axes principaux conservés. Pour une meilleure généralisation, après chaque PCA, nous avons entraîné 20 fois un modèle SVM en modifiant la distribution aléatoire entre la base de test et d'entraînement.

---

<sup>1</sup> Sariyanidi, E., Gunes, H., & Cavallaro, A., "Automatic analysis of facial affect: A survey of registration, representation, and recognition," IEEE transactions on pattern analysis and machine intelligence, 2014, vol. 37, no 6, p. 1113-1133.

Performances de la SVM après PCA en fonction du nombre de dimensions conservées



Il apparaît clairement sur le graphique que l'optimal est de conserver l'ensemble des composantes pour entraîner notre modèle. Nous avons donc rejeté l'idée d'une réduction dimensionnelle. D'autant plus que nous ne rencontrons pas de problématiques de performances durant l'utilisation du modèle.

### 3 - Recherche des meilleurs hyper-paramètres


Pour trouver une combinaison d'hyper-paramètres plus optimisée, nous voulions tenter de rechercher les meilleurs paramètres sur une plus grande plage de valeur. Pour ce faire, nous avons utilisé la bibliothèque scikit-optimize qui propose une fonction de recherche bayésienne d'hyper-paramètres. Cela permet notamment de tester des valeurs de C et de gamma sur de larges plages (entre  $10^{-3}$  et  $10^3$ ) plutôt que de tester des combinaisons de valeurs ponctuelles. Cette recherche nous a sorti la combinaison d'hyper-paramètres suivante :

'C': 3.916744597312221, 'degree': 8, 'gamma': 2.2475103435398593, 'kernel': 'linear'.



## 4 - Architecture du SVM et évaluation

Voici un aperçu de l'architecture finale retenue. Le chargement du dataset en RAM et la suppression des valeurs aberrantes se fait avec Pandas. La division de la base de données en partie tests et train, la normalisation ainsi que l'entraînement et la validation du modèle se fait avec scikit-learn, le tout dans une pipeline.



Enfin, pour évaluer les performances finales de notre architecture, nous avons exécuté 100 fois le programme avec une répartition de la base Train et Test aléatoire à chaque fois, en relevant le taux de reconnaissance. Les résultats sont les suivants :

- Taux de reconnaissance moyen : 73,3 %
- Ecart-type du taux de reconnaissance : 2,9 %
- Minimum mesuré : 64,1 %
- Maximum mesuré : 80,0 %

Sur un grand nombre de tests et avec le même type de données que celles utilisées pendant l'entraînement, le taux de reconnaissance de notre modèle devrait avoisiner 73%.

## Approche par LBP

Une première architecture SVM était donc retenue. Mais pour améliorer les performances du modèle, nous avons tenté une nouvelle approche, dite par Local Binary Pattern - LBP - comme décrite dans cet article<sup>2</sup>. L'idée générale de cette approche est de ne pas utiliser directement les landmarks fournis via un fichier csv avec notre dataset, mais d'extraire nous-mêmes les fameux "Local binary patterns" pour mieux discriminer les émotions car toutes les zones du visage n'ont pas la même importance pour discerner les émotions - cf partie data exploration.

### 1 - La démarche

Il fallait tout d'abord découper les images pour ne garder que le visage. L'approche pour reconnaître les émotions par LBP était la suivante :

1. conversion des visages en gris
2. découpage des visages en 6x7 partie de 30x35 pixels
3. application de l'algorithme de LBP sur chaque partie du visage
4. application d'un poids sur chaque histogramme généré
5. fusion de tous les histogrammes générés
6. compilation dans la SVM

Les visages sont découpés en 6x7 car certaines parties du visage ont plus d'importance pour reconnaître les émotions. Un poids sera appliqué à chaque partie du visage en fonction de son importance. Les yeux et la bouche auront une importance plus élevée que le reste du visage (cf. partie data exploration).

En ce qui concerne l'optimisation des Hyper-Paramètres du modèle SVM, nous avons utilisé les mêmes techniques de recherche que précédemment :

'C': 6.5, 'gamma': 'scale', 'kernel': 'rbf'.

---

<sup>2</sup> [Facial expression recognition based on Local Binary Patterns: A comprehensive study](#)

## 2 - Evaluation du modèle

Pour comparer nos deux approches, nous avons réalisé la même évaluation que précédemment :

- Taux de reconnaissance moyen : 73.6 %
- Ecart-type du taux de reconnaissance : 2.8%
- Minimum mesuré : 66,1 %
- Maximum mesuré : 79.5 %

Sur un grand nombre de tests et avec le même type de données que celles utilisées pendant l'entraînement, le taux de reconnaissance de notre modèle devrait avoisiner 73,5%.

## Conclusion

Bien que les résultats ne soient pas significativement meilleurs, nous avons conservé la deuxième méthode pour ses performances légèrement améliorées. C'est-à-dire l'approche par LBP plutôt que de prendre directement les landmarks fournis via un fichier csv.